

# Humanités Numériques

## Cours 3 : Linguistique et Informatique

Loïc Grobol

2021-09-21

### ***L'index thomiscus***

<https://www.corpusthomisticum.org/it/index.age>

De quoi s'agit-il ?

### **Le travail de Roberto Busa**

Roberto Busa (1913 — 2011) était un prêtre jésuite italien spécialiste de Thomas d'Aquin

According to the scholarly practices, I first > searched through tables and subject indexes for the words of *praesens* and *praesentia*. I soon learned that such words in Thomas Aquinas are peripheral : his doctrine of presence is linked with the preposition *in*. My next step was to write out by hand 10 000 3“×5” cards, each containing a sentence with the word in or a word connected with *in*. Grand games of solitaire follow. (Busa, 1980)

- 
- L'objectif initial de Busa est philosophique et théologique
  - Mais sa thèse est qu'on ne peut accéder à la pensée d'un e auteurice que si on maîtrise sa façon d'employer le langage.
  - Il lui faut donc étudier Thomas d'un point de vue philologique et linguistique.
  - Il formule donc en 1946 le projet d'un grand concordancier des œuvre de Thomas

- 
- Réalisation immédiate : la tâche est trop vaste pour être faite sans assistance
  - Il se met donc en quête de « machinerie » pour l'aider
    - any gadget that might help (Busa, 1980)
  - Il parvient à obtenir l'aide gracieuse d'IBM pour le réaliser
  - Le projet a duré 30 ans, pour produire une transcription complète de 179 ouvrage en forme lisible par des machines de l'époque (des cartes perforées !), et une lemmatisation semi-automatique.

- 
- 10 631 980 mots
  - 1 500 km de câble
  - 10 000 h de calcul
  - 1 000 000 d'heures de travail humain
-



FIGURE 1 – Roberto Busa, un homme blanc d’un certain âge en tenue ecclésiastique, pris en photo devant une étagère remplie de grands volumes : l’*index thomiscus*

## La naissance des humanités numériques

On identifie souvent l’*index thomiscus* comme le premier travail d’humanités numériques mené à terme, même si Busa suggère que d’autres initiatives plus anciennes ont existé.

Quoi qu’il en soit, c’est un travail d’une ampleur exceptionnelle pour l’époque qui a eu une influence considérable sur le développement des HN et du TAL en montrant que ce genre d’entreprise était possible.

Quelques images du projet

## Roberto • Busa : la concordance automatique

Revenons sur la thèse de Busa

Le lecteur ne doit pas simplement attacher ses propres significations aux mots qu’il lit, mais il doit aussi rechercher les significations que les mots ont pour l’auteur lui-même. Par ailleurs tous les mots fonctionnels et grammaticaux (qui dans mon esprit ne sont pas vides du tout mais au contraire très riche sur le plan philosophique) manifestent la logique la plus profonde de l’être qui génère les structures de base du discours humain ». (Busa, 1980)

- 
- L’informatique pour embrasser une masse de données
  - Mais surtout pour conduire l’analyse à un niveau jusque-là inaccessible. Il ne s’agit plus seulement d’interpréter le texte, mais aussi de l’observer comme objet.
  - La rencontre des humanités avec l’industrie
  - La mise en chiffre du monde
    - Dans la suite de Shannon, Turing : le calcul computationnel, la statistique
    - La statistique (utilisée comme politique) devient un langage de représentation de la réalité sociale (Desrosières, 2010).
  - Développement de l’étude informatique des textes.

## Bibliographie

R. Busa. 1980. The Annals of Humanities Computing : The Index Thomisticus. *Computers and the Humanities*, 14(2):83-90.

Alain Desrosières. 2010. *La politique des grands nombres*. La Découverte, éditions.