Humanités Numériques

Cours 3 : Linguistique et Informatique partie 1

Loïc Grobol

2021-09-28

L'index thomiscus

https://www.corpusthomisticum.org/it/index.age De quoi s'agit-il ?

Le travail de Roberto Busa

Roberto Busa (1913 — 2011) était un prêtre jésuite italien spécialiste de Thomas d'Aquin

According to the scholarly practices, I first > searched through tables and subject indexes for the words of *praesens* and *praesentia*. I soon learned that such words in Thomas Aquinas are peripheral: his doctrine of presence is linked with the preposition in. My next step was to write out by hand 10 000 3" \times 5" cards, each containing a sentence with the word in or a word connected with in. Grand games of solitaire follow. (Busa, 1980)

- L'objectif intial de Busa est philosophique et théologique
 Mais sa thèse est qu'on ne peut accéder à la pensée d'un e auteurice que si on maîtrise sa façon d'employer le langage.
 Il lui faut donc étudier Thomas d'un point de vue philologique et linguistique.
 Il formule donc en 1946 le projet d'un grand concordancier des œuvre de Thomas
- Réalisation immédiate : la tâche est trop vaste pour être faite sans assistance
 Il se met donc en quête de « machinerie » pour l'aider any gadget that might help (Busa, 1980)
- Il parvient à obtenir l'aide gracieuse d'IBM pour le réaliser
- Le projet a duré 30 ans, pour produire une transcription complète de 179 ouvrage en forme lisible par des machines de l'époque (des cartes perforées !), et une lemmatisation semi-automatique.
- 10 631 980 mots
 1 500 km de câble
 10 000 h de calcul
 1 000 000 d'heures de travail humain



FIGURE 1 – Roberto Busa, un homme blanc d'un certain âge en tenue ecclésiastique, pris en photo devant une étagère remplie de grands volumes : l'index thomiscus

La naissance des humanités numériques

On identifie souvent l'index thomiscus comme le premier travail d'humanités numériques mené à terme, même si Busa suggère que d'autres initiatives plus anciennes ont existé.

Quoi qu'il en soit, c'est un travail d'une ampleur exceptionnelle pour l'époque qui a eu une influence considérable sur le développement des HN et du TAL en montrant que ce genre d'entreprise était possible.

Quelques images du projet

La concordance automatique

Revenons sur la thèse de Busa

Le lecteur ne doit pas simplement attacher ses propres significations aux mots qu'il lit, mais il doit aussi rechercher les significations que les mots ont pour l'auteur lui-même.

Elle reflète entre autres les idées dites du tournant linquistique en philosophie.

Par ailleurs tous les mots fonctionnels et grammaticaux (qui dans mon esprit ne sont pas vides du tout mais au contraire très riche sur le plan philosophique) manifestent la logique la plus profonde de l'être qui génère les structures de base du discours humain ». (Busa, 1980)

Introduction de l'informatique

- Comme outil pour embrasser une masse de données
- Mais surtout pour conduire l'analyse à un niveau jusque-là inaccessible. Il ne s'agit plus seulement d'interpréter le texte, mais aussi de l'observer comme objet.
- La rencontre des humanités avec l'industrie

- La mise en chiffre du monde
 - Dans la suite de Shannon, Turing : le calcul computationnel, la statistique
 - La statistique (utilisée comme politique) devient un langage de représentation de la réalité sociale (Desrosières, 2010).
- Développement de l'étude informatique des textes.

Numériser pour compter

La notion de statistiques textuelles est antérieure à Busa et se développe parallèlement à ses travaux (Léon et Tellier, 2014).

- Jean-Baptiste Estoup (1868–1950), Georges Zipf (1902–1950) ou Gustav Herdan (1897–1968), sur les propriétés statistiques des lexiques
- Charles Muller (1909—2015), Pierre Guiraud (1912–1983), Étienne Brunet (1936) explorent les applications des statistiques lexicales et textuelles entre autres à la stylistique

On parle autour des années 80 de *lexicométrie*, puis autour des années 2000 de *textométrie*, pour rendre plus explicite qu'on ne se limite pas au simple lexique (Pincemin, 2020).

Ces évolutions vont de pair avec

- La croissance incessante des capacités matérielles de traitement (informatique)
- La généralisation du stockage numérique des documents (numérisés et créés numériquement)
- L'avènement depuis le début du 20ème siècle des méthodes quantitatives en LSHS.

Les plateformes d'analyse

L'intérêt grandissant pour les méthodes de statistiques textuelles va aussi de pair avec la création de logiciels permettant à des non-informaticien ne s de les mettre en œuvre :

- Hyperbase (1989)
- Lexico (1994)
- Le Trameur (2008)
- TXM (2010) (Heiden et al., 2010)

__ ..

Bibliographie

R. Busa. 1980. The Annals of Humanities Computing : The Index Thomisticus. Computers and the Humanities, 14(2):83-90.

Alain Desrosières. 2010. La politique des grands nombres. La Découverte, éditions.

Serge Heiden, Jean-Philippe Magué, et Bénédicte Pincemin. 2010. TXM: Une plateforme logicielle opensource pour la textométrie - conception et développement. In Luca Giuliano Sergio Bolasco Isabella Chiari, éditeur, 10th International Conference on the Statistical Analysis of Textual Data, volume 2, pages 1021-1032, Roma, Italia, mai. Edizioni Universitarie di Lettere Economia Diritto.

Ludovic Lebart et André Salem. 1994. Statistique textuelle. Dunod, éditions.

Jacqueline Léon et Isabelle Tellier. 2014. Le data turn. Des premiers traitements statistiques du langage (1950-60) à la fouille de textes. L'information grammaticale (142):30-39, juin.

Bénédicte Pincemin. 2020. La textométrie en question. Le Français Moderne - Revue de linguistique Française, 88(1):26, mars.